

RSI评测

Related doc:

[📖 RSI 同期工作/评测集调研](#)

RSI Benchmark:

分类:

分类	AI 系统改进bench	下游任务能力bench
核心问题	AI 能否通过自主研究，构建更强的 AI 系统？	AI 能否完成困难的科学、工程或其他任务？或者通过RSI来更擅长完成此类困难任务
与 RSI 的关系	直接评测 RSI 所需的系统改进能力	为 RSI 提供任务环境和效果验证的手段
优化对象	训练数据、训练算法、模型参数，以及 prompt、memory、skill、工具和 harness	具体任务的解题方案、科学模型、工程代码或设计结果
任务	改进蒸馏算法、优化训练数据、完成模型后训练、改进 Agent 记忆机制	预测科学数据、构建游戏机模拟器、优化工程方案
交付物	改进后的模型、训练流程、数据策略或可复用 Agent 组件	预测结果、科学计算方案、模拟器、代码补丁等
评测指标	能力增益、改进效率、迁移能力及收益保留情况	任务完成度、正确性、质量、运行效率
多轮迭代	持续改进 AI 系统及其能力形成机制	持续修改当前任务的解答或产物
典型代表	AI4AI-Bench 、 PostTrainBench 、 CurateBench	NatureBench 、 EmulatorBench 、 Frontier-Eng

AI 系统改进基准:

Benchmark	类别	发布机构	首次发布日期	主要评测内容	规模与范围	具体题目例子（概括）	评测指标	运行环境与预算	相关链接
AI4AI-Benchmark	AI 系统改进	Einsia.AI (Naivers Lab)，清华大学	2026/8/20	算法设计与改进：给定可执行研究仓库、起始模型和固定预算，修改训练、蒸馏、奖励建模、剪枝等算法，通过复跑检验模型是否优于初始方案。 (模型层，训练算法)	10 个任务，覆盖 10 类算法。	1. opd_math_1p5b：改进 R1-Distill-Qwen-1.5B 的在线蒸馏算法，使数学能力更强；探索时测 MATH-500，最终测 AIME 2024/2025。要求输出：训练算法源码补丁；重新训练后的模型由固定评分器测准确率。 2. ragen_sokoban_grpo：改进 Qwen2.5-3B 的多轮 GRPO 训练，让模型更会玩推箱子；最终评测 512 个保留棋盘。要求输出：可复跑的训练代码补丁及训练所得策略模型，比较解局率。 3. owl_wanda_opt6p7b_70pct：对 OPT-6.7B 进行一次性剪枝，在严格稀疏率约束下尽可能保留语言建模能力。要求输出：剪枝算法代码；生成稀疏模型，最终比较 WikiText-2 测试困惑度。	各任务原生指标映射至 [0,1]：无信息模型=0、原算法=0.1、理论最优=1；汇总取均值。原生指标含 AIME、LiveCodeBench、RewardBench、IFEval、NLL、PPL 等。	Linux amd64、Python 3.10+、Docker、NVIDIA Container Toolkit、GPU；官方使用 B300；Codex/Claude CLI。探索 4 小时/1×B300；正式复跑上限 12 小时。无训练的权重合并/剪枝任务仅执行一次。	官网： https://lab.einsia.ai/ai4ai/ 论文： https://arxiv.org/abs/2608.20318 代码： https://github.com/Einsia/AI4AI-Bench 数据： https://github.com/Einsia/AI4AI-Bench
Continua	持续技能	北京大	2026/8/4	持续技能学	5 个领域 ×	1. Finance Task 35：读取给定的财	EM、数值	Harbor	官网： https://github.c

ISkillBench	学习	学，北京通用人工智能研究院（BIGAI）		习：顺序完成任务，构建、维护和复用技能库，衡量已学技能的保留及对后续任务的帮助。（经验层，Skill积累）	100 个子任务，共 500 个子任务。	务指标，计算 The Priceline Group Inc. 从 2014 到 2015 年的百分比增长。要求输出：百分比增长率。2. Finance Task 50：根据 3M 在 2023 财年第二季度的速动比率，判断其流动性是否健康；若认为速动比率不适合衡量流动性，则解释原因。要求输出：结合财务比率的分析结论与解释。3. Finance Task 81：读取提供的财务文件，计算各项资本成本及股债权重，按给定公式求加权平均资本成本 WACC，并处理边界情况。要求输出：完成数据加载、计算、校验的程序及 WACC 结果产物。	匹配、F1、程序验证、rubric judge，按域报告 raw/normalized reward；另分析技能库大小/质量与复用。	harness、Docker；每子任务执行介绍、求解、反思与技能更新三阶段。	om/gtynnn060110-hash/continual-skill-bench-final 论文： https://arxiv.org/abs/2608.03874 数据： https://github.com/gtynnn060110-hash/continual-skill-bench-final/tree/main/Continual-Skill-Bench/tasks 题例： https://arxiv.org/pdf/2608.03874
CurateBench	AI 系统改进	Datalogy AI	2026-08（月）	训练数据优化：固定模型、优化器和训练配方，只调整数据筛选、合成及配比，检验同一个模型	3 个基座模型 × 4 项下游评测。	1. Qwen3-1.7B-Base（配置任务）：为 Qwen3-1.7B-Base 筛选、混合或合成 SFT 数据；不改模型、优化器或训练配方，让同一模型同时提高数学、代码与工具调用分数。要求输出：去污染的训练数据与混合方案；统一训练后得到四项评测结果。2. Qwen3-	四项 benchmark 的性能及平均分；关注共同模型的跨任务收益，不是	Datalogy 专有 curation stack；可联网找数据，可用指定 Qwen3-30B-A3B-Instruct-2507	官网： https://www.datalogyai.com/blog/datasmith

				在数学、代码和工具调用等能力上的整体提升。 （模型层，数据筛选）		4B-Base（配置任务）：给 Qwen3-4B-Base 设计更有效的数据方案；每次固定 350 步、367M tokens，研究过程最多提交 20 次训练。要求输出：每次候选数据资产；选出使 AIME2025、GSM8K、HumanEval、BFCL 综合表现更好的模型。 3. SmolLM3-3B-Base（配置任务）：针对 SmolLM3-3B-Base，通过实验反馈调整数据筛选、合成与配比，兼顾四类能力；可以使用指定 Qwen 模型或先前训练模型合成数据。要求输出：可供固定 SFT 流程训练的数据资产及统一评测模型。	为每项单独训练一个模型。	或先前训练模型合成。每次 SFT：350 steps、global batch 64、seq 16,384、367M tokens、lr 1e-5、8×H100；每个研究 session 最多 20 次训练提交，研究总时间不限。	
Post TrainBench	AI 系统改进	ELLS Institute Tübingen	2026/3/9	端到端 LLM 后训练：Agent 自主搜集数据、选择训练方法、安排实验，在有限算力与时间内提	4 个基础模型 × 7 个评测集，共 28 个后训练配置。	1. Qwen3-4B × AIME2025：用一张 H100 在 10 小时内自主后训练 Qwen3-4B，提升其竞赛数学表现；自行找训练数据、选择方法并安排实验。要求输出：可加载的最终模型检查点，由保留 AIME2025 题目评分。 2. Gemma-3-4B ×	目标评测集得分；主榜对 4 个模型与 7 个评测集的结果加权平均。	CLI Agent、终端与网络；HTCondor、Apptainer；每次运行 1 张 H100、10 小时。	官网： https://posttrainbench.com/ 论文： https://arxiv.org/abs/2603.08640 代码： https://github.com/aisa-group/PostTrainBench 数据： https://github.com/aisa-group/PostTrai

				升给定基础模型的目标能力。 (模型层, 训练算法+数据筛选)		HumanEval: 把 Gemma-3-4B 基础模型训练为更会按文档补全 Python 函数的模型; 论文给出一次包含数据去污染、超时恢复和 vLLM 调试的真实执行轨迹。 要求输出: 后训练模型; 通过 HumanEval 函数级单元测试衡量代码能力。 3. Gemma-3-4B × BFCL: 后训练 Gemma-3-4B, 让它根据用户要求及函数定义生成正确函数名与参数; 评分采用 BFCL v3 exec_simple。 要求输出: 后训练模型; 按 BFCL 函数调用准确率评分。			nBench/tree/main/src/eval/tasks 题例: https://arxiv.org/html/2603.08640v1
RSI Bench	RSI 评测框架	Evolvent AI	2026/7/29	模块化 RSI 研究总框架: 一次开放一个可改进组件, 固定训练、推理、评测、资源和产物管理, 隔离比较自改进方法。当前公	当前 1 个公开 Data 轨道, 覆盖 6 个目标评测; 算法、Agent/Harness、模型架构及联合优化列为后续方向。总框架没	1. 跨语言代码研究配置: 固定 Qwen3.5 目标模型和训练服务, 为跨语言代码仓库任务设计更有效的训练数据, 再用 SWE-bench Multilingual 测试修改后的模型。 要求输出: 训练数据策略与选出的模型 checkpoint; 以代码问题解决率评价。 2. 科学问答研究配置: 针对研究生级科学问答的失败, 设计和验证训练样例, 再	按具体轨道返回目标任务得分、相对基模增益、历史最佳候选及成本记录; 当前 Data	训练、模型推理、沙箱执行和评测通过服务接口隔离。当前 Data 轨道使用 Tinker、Harbor、E2B; 主实验每次研究运行	官网: https://rsibench.co/ 代码 (Data 轨道): https://github.com/evolvent-ai/RSIBench-Data 数据 (Data 轨道): https://rsibench.co/data/ 发布: https://evolvent.co/en/blog/RSIBench-Data

				开轨迹为 RSIBench-Data。（模型层，数据筛选）	有额外独立题库。	用 GPQA Diamond 反馈决定下一轮数据策略。要求输出：数据生成或筛选方案及所选 checkpoint；以科学问答准确率评价。3. Kimi 训练 Kimi 实验：由 Kimi-K2.6 研究者改进同家族模型的训练数据，诊断工具消息缺失、修复轨迹格式并比较 LoRA 候选；在固定 100 题 SWE-bench Pro 子集评测。要求输出：修正的数据转换流程、训练候选和最终 checkpoint；比较其代码任务得分与未训练基模。	轨道使用代码解决率、终端成功率和问答准确率等原生指标。	16 小时、500 美元 Tinker 费用。	
RSIBench-Data	数据驱动的自 我改进 / 自动后训练	Evolvent AI，新加坡国立大学（NUS）	2026 / 7 / 28	评估研究型 Agent 能否诊断固定目标模型的失败，设计、验证并迭代合成训练数据，再根据训练与评测反馈选择更强的 checkpoint。	6 个目标评测，共 519 道下游题：SWE-bench Verified / Multilingual / Pro 各 100 题，Terminal-	1. 官方实验配置 / AIME 数据研究：为固定 Qwen3.5 基模设计数学推理训练数据；使用非 AIME 的公开数学来源与 synthetic-data-kit，训练后依据 AIME 2026 的 30 题 avg@4 反馈迭代。要求输出：合成监督数据、允许的训练配置及最终选择的 LoRA checkpoint。2. 论文实验案例 / SWE-bench Pro：模型能修好代码却不会正确结束任	最终所选 checkpoint 的任务原生得分：SWE 问题解决率、终端任务成功率、GPQA 准确率、AIME	Python 3.12；固定 Qwen3 .5-35B-Base，Tinker LoRA SFT 与推理，Harbor + E2B 云沙箱评测；SWE 使用 Mini-SWE-Agent	官网： https://rsibench.co/data/ 论文： https://arxiv.org/abs/2607.25886 代码： https://github.com/evolvent-ai/RSIBench-Data 数据： https://github.com/evolvent-ai/RSIBench-Data/tree/main/benchmarks 题例： https://github.com/evolvent-ai/RSIBench-

				固定基 模、训 练后 端、推 理和评 测系 统，重 点考查 数据研 究策略 及迭代 改进能 力。 (模型 层，数 据筛 选)	Bench 2.0 为 89 题， GPQA Diamo nd 为 100 题， AIME 2026 为 30 题（每 题采 样 4 次）。 论文主 实验： 4 个研 究者 Agent × 6 个 目标， 共 24 组配 置。	务：补充检查最 终 diff、验证修 改、正式提交的训 练轨迹，比较真实 成功轨迹与人工合 成 finish 动作的效 果。要求输出： 更新后的训练数据 策略及经评测选出 的 checkpoint。 3. 论文实验案例 / Terminal-Bench 2.0：一次训练候 选失败后，修复数 据/训练流程，再 尝试更集中的终端 行为监督；后续停 止动作监督反而退 步时，保留历史最 佳候选。要求输 出：可执行的数据 生成流程、训练候 选及最终 checkpoint 选 择。	avg@ 4；辅 看相 对基 模增 益、 迭代 提升 与回 退、 训练/ 采样 费用 及耗 时。	，其余 使用 Termin us-2。 论文主 实验每 次研究 运行预 算 16 小时、 500 美 元 Tinker 费用。	Data/blob/main/benchmarks/ai-me/spec.json 题例： https://arxiv.org/html/2607.25886v1
SEA Gym	智能 体自 进化	清华 大学 下属 单位： 自动 化系、 BNRi st	2026 /6/1 6	自进化 智能体 评测环 境：把 Terminal- Bench 2.0 与 HLE 转 成任务 流，从 轨迹与 反馈更 新提示 词、记 忆、工 具及 harnes	论文实 例共 250 个 切分任 务： 80 训 练、 35 验 证、 55 同 分布测 试、 80 分 布外测 试；覆 盖终端 工程 及	1. polyglot-rust-c (论文实际案 例)：编写同一 份 main.rs，使 Rust 与 C++ 编译 结果都计算 Fibonacci；从 “功能正确但残留 编译文件”的失败 轨迹改进提交检 查。要求输出： 最终 /app/polyglot 目 录只保留 main.rs，并通过 功能与目录约束检 查。2. db-wal- recovery (论文实	任务 成功 率； 更新 验证 增益 UVG ；同 分布/ 分布 外增 益 IDG、 OOD G；回 放修 复/遗 忘；	Harbor 容器执 行；默 认 5 epochs 、 batch 20，共 20 次 harnes s 更 新；单 任务超 时 1,800 秒，并 发 16； 验证与	论文： https://arxiv.org/abs/2606.17546 底层数据： https://github.com/harbor-framework/terminal-bench-2 底层数据： https://huggingface.co/datasets/cais/hle 题 例： https://arxiv.org/html/2606.17546v1

				s，再评估泛化、遗忘与成本。（Harness层）	HLE 数学、物理、CS/AI、工程。	际案例）：从数据库及预写日志 WAL 恢复最终记录；需要正确重放更新，不能仅保证 JSON 可解析。要求输出：恢复结果 JSON；案例中 id=1 的值应为更新后的 150，而非旧值 100。3. video-processing（论文实际案例）：识别视频中的落地时刻，检查预测帧是否准确；该任务用于观察经验更新后是否改善细粒度验证。要求输出：output.toml 中给出落地帧；论文案例允许区间分别为 62-64 帧、231-234 帧。	tokens、工具调用、耗时与费用。	最终测试均为单次尝试。
--	--	--	--	--------------------------	---------------------	---	--------------------	-------------

下游任务能力基准：

Benchmark	类别	发布机构	首次发布日期	主要评测内容	规模与范围	具体题目例子（概括）	评测指标	运行环境与预算	相关链接
RSI-Exam	RSI 综合评测	RSI-Exam Team	2026/8/26	评测代理在长时间实验中改进现有方法或驱动冻结模型的 Harness，并将提升迁	RSI-Exam 0.1：88 项任务，35 项公开、53 项私	1. loco_longterm_memory：改造长对话记忆系统：给定4组多轮对话、812个开发问题，将原有事实抽取+BM25检索改进为更好的存储、检索和回答流程，在陌生对话上提高问答F1。要求输	各任务保留领域原生指标，再映射为统一分数：起始	Harbor + Docker；代理开发与隐藏集验证使用隔离环境。标准运行上限 12小	官网： https://rsi-exam.ai/ 代码： https://github.com/aiming-lab/RSI-Exam 数据： https://huggingface.co/datasets/RSI-Exam/RSI-Exam 题例：

				移到未见数据的能力。代理从弱基线出发，提出假设、实现、测试和保留改动，最终接受隐藏集评测。	有；6个领域：AI模型与代理18、物理学与工程19、优化/规划/控制18、系统与硬件13、生命科学与医学12、金融/法律/商业8。	出：可执行 memory_system.py ，提供 ingest/answer 接口；底座固定为 gpt-4o-mini。2. discoveryworld_agent_harness_low2：改造 ReAct 科研代理，在“太空疾病”和“组合化学”模拟世界中设计实验、保留记忆并解释发现；开发用6个世界，最终在未见参数种子上限240步完成调查。要求输出：改进的 agent.py 和实验记录；按任务进展、完成率、解释性知识准确率评分。3. legal_matter_caseload_regulatory：阅读6起法律事务的1000余份材料，处理电话营销合规、GDPR、药品标签、关税和交易等问题；通过18个可反馈问题学习如何完整作答，再回答18个保留问题。要求输出：answers.json 中的18份法律分析答案；每题全部评分条件满足才算通过。	基线0；可使用时经实测校准的强参考0.6；理论或理想上界1。主榜为88项隐藏集归一化分数的等权平均；另记录运行时间、费用与输出 token。	时，公开运行配置为50万输出 token；CPU/GPU/TPU及任务内调用预算依题目设置。网络仅允许模型服务及必要认证端点；部分任务另需冻结模型或 judge API。	exam.ai/tasks/locomo_longterm_memory.html 题例： https://rsi-exam.ai/tasks/discoveryworld_agent_harness_low2.html 题例： https://rsi-exam.ai/tasks/legal_matter_caseload_regulatory.html
NatureBenc	科研与工程	Frontis.AI Hori	2026/7/30	科学机器学习：根据科学	10个固定任务，	1. s42256-023-00611-x：分类反事实结果估计：利用 German	相对论文 SOTA 的方	任务容器与独立评分服务；	官网： https://github.com/FrontisAI/OpenRSI/tree/ma

h Lite		zon Rese arch ；联 合机 构： 清华 大学		问题和 数据自 主设计 并实现 模型， 比较已 发表 Nature 系列论 文的最佳 结果；用 于测试 机器学习 工程能力向 科学问题的迁 移。	取自 90 题 的 Natu reBe nch 。	credit、IST aspirin、IST heparin 和 Twin mortality 四个子 数据集建模，预测 干预条件变化时的 分类结果。要求输 出：预测代码与各 子集预测结果；按 四个子任务相对原 论文SOTA的归一 化差距评分。2. s42256-023- 00627-3：微生物 组成→代谢组谱： 给出样本的微生物 群落组成数据，建 立模型预测该样本 的代谢物组成/丰 度谱。要求输出： 可执行模型代码及 测试样本的代谢组 预测结果。3. s41467-025- 65557-7：单分子 定位点云聚类：给 出显微成像得到的 单分子空间坐标点 云，识别其中的空 间簇，把来自相同 结构的定位点聚在 一起。要求输出： 点云的空间聚类/ 分割结果及实现代 码。	向归 一化 差距 g； Match - SOTA: g≥0 ； Surpa ss- SOTA: g>0.1 ；并 检验 解答 有效 性。	CPU/G PU 随 题配 置；正 式协议 禁用网 页搜 索。每 题 4 小 时。	in/OpenMLE-Evo/benchmarks/naturebench_lite_v2 论文： https://arxiv.org/abs/2607.28568 代码： https://github.com/FrontisAI/OpenRSI 数据： https://huggingface.co/datasets/FrontisAI/NatureBench 发布： https://github.com/FrontisAI/OpenRSI/commit/43e84eacb9c9311ee1191810892a2df4f7304c68 题例： https://github.com/FrontisAI/OpenRSI/blob/main/OpenMLE-Evo/benchmarks/naturebench_local_quick/RESULTS.md 题例： https://huggingface.co/datasets/FrontisAI/NatureBench/blob/main/manifest.jsonl
PPT bench (Einsia , 2026)	推理 与视 觉	Einsia.AI (Navers Lab)	2026 /9/1	科学流程图重建：输入科研论文中的流程图或架构图，生成保	500 个冻 结任 务， 来自 13 个 科学 领域。	1. TDFlow · agentic workflows for test-driven development：给 定面向测试驱动开 发的多 Agent 工作 流图，把其中的角 色模块、步骤和交	三阶 段评 分： 文件 与原 生可 编辑 性检 查 →	生成并 提交单 页 .pptx； 评分器 检查能 否打 开、渲 染及原	官网： https://lab.einsia.ai/pptbench/ 数据： https://lab.einsia.ai/pptbench/#tasks 发布： https://lab.einsia.ai/research/

				留科学语义和视觉结构的单页、原生可编辑 PowerP oint 文件。		互关系重建为单页演示文稿。 要求输出：由原生可编辑文本、形状和连接线组成的 PPTX。 2. MegaFold protein-model architecture：给定 MegaFold 蛋白质模型的架构图，重建模型模块、数据流和文字标注，保持原图的科学含义与布局。 要求输出：单页原生可编辑 PPTX，模块与文字可以单独修改。 3. Cryogenic predecoder for surface-code decoding：给定用于表面码解码的低温预解码器示意图，在 PowerPoint 中重建组件、连线 and 标签。 要求输出：能打开和渲染的单页 PPTX；组件及连线保持原生可编辑。	语义及渲染门槛 → 版式、文本、图形等视觉细节排序。	生对象可编辑性。统一时间与算力预算未披露。	
Emu lator Ben ch	科研与工程	Prime Intellect	2026/8/5	长程复杂编码：根据硬件规范与诊断测试，用 Rust 从零构建游戏机模拟器，检验底层	16 个模拟器重建任务。	1. SEGA Genesis：SEGA Genesis模拟器：根据目标主机规范和诊断测试，从零编写Rust模拟器，在隔离环境中工作，不能使用参考实现。 要求输出：可运行的 Rust 模拟器，通过目标机器的行为诊断测试。 2. Nintendo	人类编写的诊断程序检验模拟行为正确性；展示得分与成	Rust 工具链、沙盒、诊断测试评分器；统一运行预算未披露。	官网： https://www.primeintellect.ai/blog/prime-agent 代码： https://github.com/PrimeIntellect-ai/prime-agent

				系统行为和跨模块实现是否正确。		Game Boy Color: Game Boy Color模拟器: 根据这款掌机的规范和诊断测试, 从零实现Rust模拟器; 需要正确模拟CPU标志、图形时序等系统行为。要求输出: 可运行的 Rust 模拟器, 通过目标机器的行为诊断测试。	本曲线。		
OpenMLE-Gym	AI 系统改进	Frontis.AI Horizon Research; 联合机构: 清华大学	2026/7/30	机器学习工程任务环境: 根据任务说明与数据完成训练、调试和预测, 用可执行评分器反馈支持程序演化、自动实验和长期搜索。	4,343 条可重建配方 (4,196 个不同 Task ID); 1,415 个即用任务包。	1. brain-tumor-detection-mri@1 / 图像分类: 给定脑部 MRI 数据, 编写并运行脑肿瘤分类训练程序, 为测试图像生成预测; 论文公开的实际 GPU 作业限时 3600 秒。要求输出: 候选 Python 程序及 submission.csv 预测文件, 交由任务指标评分。2. ddos-ciciot2023@1: 给定 CICIoT2023 物联网流量数据, 完成 DDoS 攻击识别任务, 设计并实现机器学习训练与预测流程。要求输出: 可运行的 Python 程序及测试数据预测结果。	由任务的 utils/metri c.py 和元数据指定, 包括 higher_is_b etter 与上下界; 无统一原生指标。	Python 3.10+、uv; 按任务配置 CPU/GPU 沙盒、依赖与运行限额。部分数据配方需上游平台账号。	官网: https://github.com/FrontisAI/OpenRSI 论文: https://arxiv.org/abs/2607.28568 数据: https://huggingface.co/datasets/FrontisAI/OpenMLE- 题例: https://arxiv.org/pdf/2607.28568 题例: https://huggingface.co/datasets/FrontisAI/OpenMLE-SFT-Traces
ASIBench	科研与工程	Apex Intel ligen ce、	2026/4/22	科研项目执行与方法自主性: 完	60 个正式任务; 每个	1. 2D Anisotropic Stiff Dynamics: 给定二维非线性系统的时空场快照、初始条件和参数,	任务专属 gates/weights	Docker 或命名空间隔离; 按任务安	官网: https://asibench.apexin.ai/ 论文: https://arxiv.org

		清华大学		成可验证的科学计算和实验任务；通过由强到弱的四档方法提示，衡量遵循方案和自主设计方法的能力。	任务4档条件；另提供5个完整公开样例。	自主建立能复现动力学的模型，预测目标时刻的二维场并提取物理特征。要求输出：预测场、空间频谱、物理诊断、科学可视化和完整仿真代码。2. math.homotopy_poly_roots：求给定多项式方程组的全部孤立复数根。方法提示强的版本给同伦延拓方向，方法提示弱的版本需自己确定求解流程。要求输出：全部孤立复数根及任务指定的科研结果文件。3. LiDAR-IMU Time-Offset and Yaw-Extrinsic Calibration：依据提供的激光雷达与IMU数据，标定两传感器的时间偏移和偏航角外参。要求输出：时间偏移、偏航角外参与可复现的标定代码。	scorers 汇总为 0–100 分，分别报告 B1–B4；科研逻辑、数值/产物准确性随任务定义。	装依赖，超时由实例配置指定。	/abs/2608.17271 代码： https://github.com/apexin-ai/ASI-Bench 数据： https://huggingface.co/datasets/Apexintelligence-AI/ASI-Bench-seed31415 题例： https://arxiv.org/pdf/2608.17271
Frontier-Eng	科研与工程	Einsia.AI (Navers Lab)	2026/4/14	工程方案优化：给定工程问题、初始实现及可运行仿真器，在有限交互预算下利	完整版 47 个任务；Lite 子集 10 个任务。	1. EnergyStorage / BatteryFastChargingProfile：从保守充电方案出发，为锂离子电池设计多阶段恒流充电曲线，在电压、温升和衰减约束下缩短充电时间。要求输出：各阶段电流与SOC 切换点/策略	平均排名（越低越好）、性能分布和胜率；另提供基	Linux、逐任务 Python 环境与仿真器；部分任务需 CUDA、Docker	官网： https://github.com/Einsia/Frontier-Engineering 论文： https://arxiv.org/abs/2604.12290 数据： https://github.com/Einsia/Frontier-Engineering/tree

				用执行反馈改进可行方案，覆盖能源、计算系统和控制等领域。		代码，交由电化-热-老化仿真器评分。2. ComputerSystems / MallocLab：改进一个初始内存分配器，使它支持有效的空闲块复用、合并和元数据管理，同时提升运行效率与内存利用率。要求输出：可执行内存分配器实现，由固定测试与性能评分器评估。3. SustainableDataCenterControl / hand_written_control：为数据中心联合控制负载迁移、制冷和电池，在四种场景中减少碳排和用水，同时避免任务被丢弃或超时。要求输出：每步读取状态并返回联合动作的控制策略代码，比较四场景综合仿真分数。	于金银铜门槛的 Medal Score 。	或 Octave 。论文主比较每任务 100 次迭代。	e/main/benchmarks 题例： https://arxiv.org/html/2604.12290v1
APEX-Agents	专业工作	Mercor	2026/1/20	专业跨应用工作：在企业工作环境中处理文件、模型和办公应用，完成投资银行、咨询及	480 个任务，33 个企业环境；投行、咨询、法律各	1. KVUE 市盈率计算：读取 DCF 模型中的隐含股价及 2025-12-23 年度财务文件中的稀释每股收益，计算 KVUE 的市盈率。要求输出：返回保留两位小数的 P/E 比率。2. 油气公司人均营收分析：在欧洲油气公司降本项目环境中，跨文	Pass @1；同时报告 Pass @8、Pass^8、平均 rubric 分数。每任	Archipelago 执行和评测框架，提供文件及办公工具；禁用网页搜索。Agent 统一预	官网： https://www.mercor.com/apex/ 论文： https://arxiv.org/abs/2601.14242 代码： https://github.com/Mercor-Intelligence/archipelago 数据： https://huggingface.co/datasets/

				法律工作中的实际交付任务。	160 个任务。	件汇总各站点过去几年的员工人数和营收。要求输出：制作展示各站点历年人均营收的演示文稿。	务1-10项二元 criteria，逐项 judge。	算未披露。	mercor/apex-agents/tree/main 题例： https://arxiv.org/html/2601.14242v3 题例： https://www.linkedin.com/posts/brendan-foody-2995ab10b_ai-agents-have-entered-the-workforce-but-activity-7419796934451806209-S8P3
Continual Learning Bench (CL-Bench)	持续学习与记忆	加州大学伯克利分校	2026/5/4	在共享潜在规律、可发生概念漂移的连续任务中，测量智能体能否利用历史经验提高表现；用有状态与无状态运行的差值区分持续学习和静态能力。	6 个领域；默认每轮合计 301 个实例：频谱 90、代码 19、队列研究 20、数据库 40、扑克 120、销量 12。	1. blind_spectrum_monitoring / 395 MHz 示例：395 MHz 发射器曾在前六次扫描中的两次出现，本次消失；结合历史判断它是不存在还是暂时休眠。要求输出：保留该发射器及频谱信息，标记 currently_active=false。 2. cohort_studies / HERALD→MERIDIAN：接收编码不一致的两项 VAS 疾病研究，把 MERIDIAN 的 geno3 对齐之前学到的基因型编码，修正跨研究生存估计。要求输出：36 类人群在 12、24、36 个月的生存概率表。 3.	Reward；Gain = 有状态奖励一同系统无状态奖励；跨任务归一化 Reward/Gain；另报频谱 IoU、修复/查询效率、生存预测信息	Python 3.13+、uv；容器任务需本地 Docker，模型 API 按实耗计费。论文每任务通常 5 轮；代码修复每实例至多 40 步、数据库每题至多 15 次探索查询。	官网： https://continual-learning-bench.com/ 论文： https://arxiv.org/abs/2606.05661 代码： https://github.com/pgasawa/continual-learning-bench 数据： https://github.com/pgasawa/continual-learning-bench/tree/main/data 发布： https://continual-learning-bench.com/news/cl-bench-1-0/ 题例： https://arxiv.org/html/2606.05661v1

						exploitable_poker/ calling_station: 在此前摊牌中发现 对手持续跟注、不 诈唬也不弃牌；后 续牌局据此调整价 值下注，并在对手 策略切换后继续适 应。要求输出：合 法扑克动作及下注 额；以每手平均大 盲收益评估。	增 益、 扑克 收 益、 WAPE skill、 API 费 用。		
--	--	--	--	--	--	--	---	--	--

总结：

1. **AI 系统改进基准：**主要评估的是 AI 能否改善模型或者系统，属于L1-L3，核心缺点在于没有衡量**改进和进化能力**是否也在加强。
2. **下游任务能力基准：**主要评估的模型的能力，长程+困难任务，能力提升偏向于 Continual Learning 的范式

改进链条：

系统自主产生改进 → 改进被下一代继承 → 下一代在新问题上更擅长改进系统 → 优势继续传递
 在RSI链条中，应该同时评估模型：

1. 完成具体任务的能力
2. 改进小系统的能力
3. 改进自身的能力
3. 改进能力是否提升

TBD：

1. 2个月之后报分的事情
2. 传达评测认知，eval tech report
3. 敲定 Benchmark
4. benchmark挑选subset，考虑覆盖范围和时间成本
5. 方案DDL，周日